

INFORME TÉCNICO Y OPERATIVO EXHAUSTIVO

Procesamiento y Extracción de Información en el Módulo de Expedientes

TERRITORIUM LEGALÍTICA · SISTEMA EXPERTO DE GESTIÓN Y CONSOLIDACIÓN JURÍDICA INMOBILIARIA

1. INTRODUCCIÓN Y ALCANCE DEL MÓDULO

El **Módulo de Expedientes** de Territorium es el núcleo de ingeniería documental y analítica predial diseñado para transformar colecciones heterogéneas, desestructuradas y masivas de documentos jurídicos, técnicos y económicos en un **Consolidado Maestro Predial Inmutable**, validado estructuralmente y apto para la generación automatizada de minutas y contratos notariales.

En proyectos de infraestructura, energía, saneamiento predial e hidrocarburos en Colombia, la conformación de un expediente inmobiliario enfrenta retos severos:

- Documentos en formatos múltiples (PDF escaneados, PDF vectoriales, actas notariales en formato Word **.docx**, y matrices financieras en hojas de cálculo **.xlsx**).
- Discrepancias intrínsecas entre escrituras públicas antiguas, certificados de tradición y libertad (CTL), levantamientos topográficos y ofertas comerciales de negociación.
- Errores humanos de digitación en cédulas catastrales, números de documento de propietarios y transcripción deficiente de linderos.

El presente informe detalla exhaustivamente cada etapa del pipeline, desde la recepción física del archivo hasta la consolidación final y la exportación de documentos oficiales.

```
flowchart TD
    A[Archivos] --> B[Storage]
    A --> C[Máquina de Estados]
    A --> D[Worker]
    A --> E[Enrutamiento]
    A --> F[Negociación]
    A --> G[Títulos]
    A --> H[Planos]
    A --> I[Planos]
    A --> J[Planos]
    A --> K[Expediente]
    A --> L[Consolidación]
    A --> M[Generación]
    A --> N[PDF]
```

2. ARQUITECTURA DE TRES CAPAS Y ROLES DE COMPONENTES

El sistema opera bajo un desacoplamiento estricto entre tres entornos de ejecución:

Capa	Tecnologías	Rol y Responsabilidad Primaria
Frontend (Cliente)	React 18, Vite, TypeScript, Lucide Icons, html2pdf.js	Interfaz de usuario reactiva, workspace de expediente, revisión visual de discrepancias, aprobación por grupos, selección de plantilla y renderizado interactivo con zoom/scroll.
Persistencia & Transacciones	Supabase (PostgreSQL 15), Row Level Security (RLS), PL/pgSQL RPCs, Storage	Gestión de estados transaccionales (draft , ready , review_ready , approved , stale , error), tokens de arrendamiento (lease_token), logs inmutables de IA y almacenamiento de blobs.
Motor de Procesamiento (Worker)	Python 3.11, FastAPI, Uvicorn, OpenAI API (GPT-4o), OpenPyXL, PyPDF, python-docx	Extracción canónica, segmentación semántica, Map-Reduce de fragmentos, validación de reglas de negocio inmobiliario colombiano y generación de matrices de discrepancias.

3. EL MODELO CANÓNICO DE DOCUMENTOS (CanonicalDocument)

A diferencia de sistemas convencionales que pasan texto plano sin estructurar a los modelos de lenguaje, Territorium convierte cada documento cargado en una representación orientada a objetos denominada **CanonicalDocument**.

3.1 UNIDADES ESTRUCTURALES (UNITTYPE)

Cada archivo es desglosado jerárquicamente en:

- **paragraph**: Párrafo narrativo con delimitación de saltos de línea.
- **table_cell** y **table_row**: Datos tabulares preservando relación fila-columna.
- **table**: Bloques de tablas (frecuentes en cuadros de áreas y anotaciones de folios).
- **page**: Delimitación física de página para PDFs.
- **excel_cell**: Coordenada precisa (**A1**, **C14**) para hojas de cálculo.

3.2 CLASIFICACIÓN DE ESCANEО Y CALIDAD (SCANCLASSIFICATION)

Antes de intentar la extracción, el módulo **scan_detector.py** analiza cada página mediante métricas de densidad textual:

1. **TEXTUAL**: La página contiene texto digital incrustado (capa vectorial legible). El ratio de caracteres por unidad de área es óptimo.
2. **SCANNED**: La página es una imagen rasterizada pura (sin capa de texto). Requiere OCR antes del análisis textual.
3. **MIXED**: Contiene sellos o firmas superpuestas pero conserva fragmentos textuales analizables.
4. **PROTECTED**: Archivo con restricciones criptográficas de lectura o permisos bloqueados por la notaría.
5. **CORRUPT**: Bytes no conformes con el estándar PDF/DOCX.

3.3 TRAZABILIDAD INMUTABLE: DOCUMENTFRAGMENT Y FRAGMENTLOCATOR

Cada fragmento extraído contiene:

- **fragment_id**: Identificador único determinista (UUID v5 / hash).
- **locator**: Objeto que guarda **document_id**, **original_name**, **page_number**, **unit_type**, **unit_index** y **location_label** (ej: "Página 3, Párrafo 4" o "Hoja 1, Celda F12").
- **confidence**: Puntuación de confianza (0.0 a 1.0).

4. CICLO DE VIDA COMPLETO: PASO A PASO ORDENADO

Para garantizar el resultado con total certidumbre jurídica, el procesamiento sigue una secuencia ordenada de siete (7) fases:

```
sequenceDiagram
    actor Actor as Usuario / Abogado
    participant UI as Frontend React
    participant DB as Supabase PostgreSQL
    participant WK as Worker Python (Pipeline V2)
    participant AI as Proveedor IA (GPT-4o)

    Actor->>UI: Carga archivos (.pdf, .docx, .xlsx)
    UI->>DB: Almacena en Storage & Registra en expediente_files
    UI->>DB: Invoca enqueue_expediente_execution(group_id)
    DB->>UI: Retorna execution_id en estado 'queued'
    WK->>DB: Polling claim_next_expediente_execution()
    DB->>WK: Arrienda ejecución con lease_token único
    WK->>DB: Descarga bytes de los archivos del grupo
    WK->>WK: Parsea a CanonicalDocument & Detecta OCR
    alt Grupo Negociación
        WK->>WK: NegotiationExtractor (OpenPyXL)
    else Grupo Títulos
        WK->>AI: TitleStudyExtractor (Prompt Especializado)
    else Grupo Planos
        WK->>AI: PlanExtractor (Prompt Cartela + Áreas)
    else Grupo Planos
        WK->>WK: HierarchicalReducer (Map-Reduce & Discrepancias)
    else Grupo Reparación auditable
        WK->>DB: Guarda resultado en expediente_execution_outputs
    else Grupo Actualiza grupo a 'review_ready'
        UI->>Abogado: Muestra datos en workspace para revisión
    else Grupo Aprueba grupo individualmente
        UI->>UI: Al aprobar los 3 grupos, ejecuta consolidateApprovedGroups()
    else Grupo Despliega modal obligatorio de selección
        UI->>Abogado: Despliega plantilla y visualiza minuta final
    else Grupo Solicita exportación DOCX & Exporta PDF de alta fidelidad
```

PASO 1: INGESTA, HASHING Y CONTROL DE VERSIONES

- El usuario sube los archivos en el panel correspondiente a su grupo:
 - Títulos:** Escrituras públicas, Certificados de Tradición y Libertad (CTL), resoluciones del INCODER/ANT.
 - Planos:** Levantamientos topográficos, planos de servidumbre en PDF.
 - Negociación:** Ficha de negociación predial en formato Excel **.xlsx**.
- El sistema calcula en cliente el hash SHA-256 de los bytes del archivo para evitar reprocesamientos redundantes y garantizar la cadena de custodia probatoria.
- Se registran en la tabla **expediente_files**. Si el grupo estaba previamente en estado **approved** o **review_ready**, la adición o retiro de un archivo incrementa el **input_version** y transiciona el grupo a **ready**, invalidando ejecuciones obsoletas mediante **superseded**.

PASO 2: ENCOLAMIENTO TRANSACCIONAL Y CONCURRENCIA IDEMPOTENTE

1. El frontend ejecuta el procedimiento almacenado transaccional **enqueue_expediente_execution(p_group_id, p_project_id, p_triggered_by)**.
2. La función de PostgreSQL:
 - Cancela cualquier ejecución en progreso anterior marcándola como **superseded**.
 - Inserta un nuevo registro en **expediente_executions** con estado **queued** y prioridad configurable.
 - Actualiza el estado del grupo a **queued**.
3. El Worker Python ejecuta una rutina en segundo plano mediante **claim_next_expediente_execution()**. Esta función utiliza **FOR UPDATE SKIP LOCKED** a nivel de base de datos, garantizando que múltiples workers nunca tomen el mismo trabajo ni generen condiciones de carrera (*race conditions*). Se genera un **lease_token** criptográfico con vencimiento de 10 minutos.

PASO 3: EJECUCIÓN ESPECIALIZADA POR GRUPO DOCUMENTAL

A. Grupo de Negociación (**negotiation_extractor.py** & **negotiation_reader.py**)

- **Extracción 100% Determinista:** No depende de inferencia probabilística. Utiliza la librería **openpyxl** para recorrer el libro contable de negociación.
- **Búsqueda Inteligente de Coordenadas:**
 - Localiza la celda del código del predio objetivo (**target_property_code**).
 - Extrae los valores de la 1ª Oferta, 2ª Oferta y Oferta Definitiva.
 - Valida coherencia financiera: si el valor de la oferta no coincide con el avalúo catastral o comercial registrado, registra una discrepancia aritmética.
- **Conversión Numérica a Letras:** Aplica el algoritmo de transcripción monetaria oficial colombiana (ej. \$ **15.000.000** -> "QUINCE MILLONES DE PESOS MONEDA CORRIENTE").

B. Grupo de Estudio de Títulos (**title_extractor.py**)

- **Segmentación Semántica:** Si el documento contiene más de 8.000 tokens (típico en escrituras públicas de 40 páginas), el módulo **segmentation.py** divide el texto en secciones lógicas (Identificación del Inmueble, Antecedentes, Cláusulas, Gravámenes, Otorgantes).
- **Extracción Asistida por IA (OpenAI GPT-4o):**
 - Se invoca el modelo con **temperature=0.0** y **response_format={"type": "json_object"}**.
 - Se inyecta el **TITLE_STUDY_SYSTEM_PROMPT**, el cual contiene 13 reglas jurídicas colombianas obligatorias:
 1. **Folio de Matrícula:** Formato con código ORIP (ej: **324-72404, 050N-204581**).
 2. **Cédula Catastral:** 15 a 30 dígitos numéricos.
 3. **Propietarios Vigentes:** Solo titulares actuales de dominio pleno o nuda propiedad.
 4. **Linderos Exactos:** Transcripción literal sin resúmenes desde el punto de partida hasta el cierre.
 5. **Modo de Adquisición:** Acto jurídico, tradente, instrumento público y número de anotación en el folio.
 6. **Condiciones Jurídicas:** Gravámenes, afectaciones a vivienda familiar, embargos o la leyenda obligatoria "sin condiciones jurídicas vigentes".
 7. **Radicados Especiales:** Casos de restitución de tierras (URT) y consultas ante el Ministerio de Justicia.
- **Mecanismo de Resiliencia (Fallback Heurístico Regex):** Si la API de IA presenta timeout, indisponibilidad o falla de cuota, el extractor activa automáticamente el motor **_heuristic_extract()**. Este motor cuenta con patrones de expresiones regulares pre-entrenados sobre el lenguaje notarial colombiano para extraer matrículas, propietarios y linderos sin detener la operación.

C. Grupo de Planos Topográficos (**plan_extractor.py**)

- **Análisis de Cartela Técnica:**
 - Extrae el código oficial del plano, escala (ej: **1:1000**), fecha de elaboración y profesional responsable.

- Identifica el nivel de tensión de la línea de transmisión (ej: **115 kV, 230 kV, 500 kV**).
- **Geometría de la Servidumbre:**
 - Área de afectación total y franja de servidumbre (números y letras en metros cuadrados o hectáreas).
 - Longitud del eje en metros lineales.
 - Ancho de la franja de seguridad (ej: **30 metros, 15 metros a cada lado del eje**).
 - Cuento de infraestructura física (número de torres, postes o apoyos proyectados dentro del predio).

5. REDUCCIÓN JERÁRQUICA Y DETECCIÓN DE CONFLICTOS (HierarchicalReducer)

Quando un expediente contiene múltiples escrituras, certificados o planos, el **HierarchicalReducer** ejecuta un proceso de agregación estructurada:

[illegible]

5.1 REGLAS DE FUSIÓN Y PREVALENCIA

- 1. Colección de Propietarios:** Se de-duplican por número de documento de identidad (**document_number**). Si un propietario aparece en la escritura antigua pero en el CTL vigente fue transferido, prevalece la titularidad vigente.
- 2. Linderos Literales:** El reductor selecciona la transcripción de mayor longitud y detalle descriptivo (**longest_boundaries**), preservando el estándar notarial de cierre perimetral.
- 3. Modos de Adquisición:** Se concatenan cronológicamente con separadores dobles (//), estructurando la cadena de tradición del predio.

5.2 DETECCIÓN DE DISCREPANCIAS CRUZADAS (FIELD DISCREPANCY)

Si el Documento A indica que el predio se llama "*La Esperanza*" y el Documento B indica "*El Recreo*", o si las áreas presentan diferencias mayores a 0.01 m², el reductor no sobrescribe el dato silenciosamente:

- Genera una entrada en **discrepancies** con:
- **field_name**: Campo en conflicto.
- **values**: Lista de valores divergentes encontrados.
- **sources**: Nombres de los archivos donde se encontró cada valor.
- **description**: Explicación legible para el abogado revisor.

6. MOTOR DE VALIDACIÓN ESTRUCTURAL Y REPARACIÓN AUDITABLE (StructuralValidationEngine)

Antes de entregar el resultado al usuario, el motor **validator.py** somete la información a un control de calidad normativo mediante funciones puras:

```
flowchart LR
    A[Payload Canónico Bruto] --> B[validate_and_normalize_folio]
    B --> C[validate_and_normalize_cadastral_id]
    C --> D[validate_and_normalize_doc_number]
    D --> E[validate_boundaries_text]
    E --> F{¿Hubo cambios?}
    F --> Si[Si]
    Si --> G[Registra AuditRepair: campo, valor previo, valor reparado, justificación]
    G --> No[No]
    No --> H[Sin modificaciones]
    H --> I[ValidationReport: is_valid, errors, warnings, audit_repairs]
    I --> H
```

6.1 CATÁLOGO DE REGLAS INMOBILIARIAS IMPLEMENTADAS

Regla	Función	Comportamiento y Validación	Acción en Caso de Inconsistencia
Folio de Matrícula	validate_and_normalize_folio	Verifica patrón <code>^\d{3}[A-Za-z]?-\d{5,8}\$</code> . Elimina espacios, guiones dobles o letras espurias.	Si tiene formato recuperable, lo formatea y genera AuditRepair . Si es inválido, emite ValidationIssue de severidad error .
Cédula Catastral	validate_and_normalize_cadastral_id	Comprueba longitud de 15, 20 o 30 dígitos numéricos según la resolución IGAC.	Remueve caracteres no numéricos. Si no cumple la longitud legal, marca advertencia técnica.
Documentos de Identidad	validate_and_normalize_doc_number	Limpia puntos, comas y espacios en Cédulas de Ciudadanía y NITs. Calcula y valida dígito de verificación en NIT.	Normaliza a sólo dígitos numéricos. Deja registro auditable del cambio.
Cierre de Linderos	validate_boundaries_text	Busca puntos cardinales (NORTE, SUR, ORIENTE/ESTE, OCCIDENTE/OESTE) y expresiones de cierre (" <i>punto de partida</i> ", " <i>encierra</i> ").	Si faltan puntos cardinales, emite warning indicando que los linderos pueden estar incompletos.
Titularidad Actual	validate_titles	Valida que la lista de propietarios contenga al menos un titular con nombre y cédula.	Si la lista está vacía, bloquea la aprobación con severity="error" .

7. APROBACIÓN TRANSVERSAL Y CONSOLIDACIÓN MAESTRA (expedienteConsolidation.ts)

Para salvaguardar la seguridad jurídica de la compañía, ningún documento final puede generarse a partir de datos no verificados.

7.1 EL REQUISITO DE LA TRIPLE APROBACIÓN

El expediente requiere que un abogado especialista revise y apruebe individualmente cada uno de los tres componentes:

- 1. **Aprobación de Títulos:** Revisa folio, titulares, linderos y gravámenes.
- 2. **Aprobación de Planos:** Revisa franja de servidumbre, áreas y apoyos.
- 3. **Aprobación de Negociación:** Revisa ofertas y valores acordados.

7.2 FUSIÓN EN EL CONSOLIDATEDMASTERRECORD

Una vez aprobados los tres grupos, la función `consolidateApprovedGroups()` fusiona los payloads en un único objeto inmutable:

- Registra los IDs de versión exactos aprobados: **titles_result_version_id**, **plans_result_version_id** y **negotiation_result_version_id**.
- Guarda la estampa de tiempo **consolidated_at** y el usuario responsable **consolidated_by**.
- El consolidado queda sellado. Si en el futuro un archivo es modificado en cualquiera de los grupos, el estado del grupo pasa a **stale** o **ready**, pero el consolidado histórico mantiene su trazabilidad completa.

8. GENERACIÓN DOCUMENTAL Y EXPORTACIÓN DE ALTA FIDELIDAD

Una vez aprobado el consolidado maestro, el flujo no salta de forma descontrolada a generar un documento aleatorio. El sistema implementa una compuerta obligatoria:

[illegible]

8.1 SELECCIÓN OBLIGATORIA DE PLANTILLA

El usuario debe escoger explícitamente entre el catálogo de plantillas jurídicas oficiales:

- Minuta de Constitución de Servidumbre de Energía Eléctrica.
- Promesa de Compraventa de Inmueble Rural.
- Poder Especial Amplio y Suficiente.
- Acta de Concertación y Permiso de Intervención.

8.2 VISUALIZADOR INTERACTIVO DE DOCUMENTO

El documento se renderiza en pantalla con características ergonómicas avanzadas:

- **Scroll Vertical Interno:** La tarjeta del documento mantiene altura contenida con desplazamiento interno, evitando scroll de la ventana principal.
- **Zoom Dinámico:** Controles de acercamiento/alejamiento (**Zoom In, Zoom Out, Reset**) y soporte nativo de gestos táctiles (pinch-to-zoom) mediante touchpad.

8.3 MOTORES DE EXPORTACIÓN DE ALTA FIDELIDAD

1. Exportación Oficial a Microsoft Word (.docx):

- Endpoint de FastAPI **/api/documents/export-docx** implementado con **python-docx**.
- Formato institucional con márgenes legales (3 cm superior e izquierdo, 2 cm inferior y derecho), tipografía formal (Arial / Times New Roman) y tablas estructuradas.

2. Exportación a PDF de Alta Fidelidad (html2pdf.js):

- Generación WYSIWYG directa a partir del contenido exacto del visualizador HTML.

- Encabezado institucional de Territorium, numeración de páginas, código hash de verificación y firma de auditoría en el pie de página.

9. MATRIZ DE RIESGOS, MITIGACIONES Y DETERMINISMO

Riesgo Técnico / Operativo	Impacto Potencial	Mitigación Implementada en el Sistema
Alucinación de IA	Inclusión de propietarios ficticios o linderos alterados.	Prompt con restricción estricta de subcadena exacta + Fallback heurístico determinista + Validación de citas obligatorias.
Documentos Escaneados sin OCR	Omisión de información crítica en escrituras antiguas.	Detección preventiva con ScanClassification . SCANNED y alerta temprana al usuario antes de procesar.
Condiciones de Carrera (Workers concurrentes)	Sobrescritura de ejecuciones o procesamiento duplicado.	RPC en PostgreSQL con FOR UPDATE SKIP LOCKED y arrendamiento con lease_token .
Modificación de Archivos tras Aprobación	Disparidad entre lo aprobado y los archivos en disco.	Procedimiento expediente_retire_file que invalida aprobaciones y transiciona el grupo a ready .
Divergencia entre Plantilla y Documento Exportado	El PDF descargado no refleja el texto editado en pantalla.	Integración directa de html2pdf.js capturando el DOM exacto del visualizador editable.

10. CONCLUSIÓN

El Módulo de Expedientes de Territorium redefine el estándar de procesamiento jurídico-técnico inmobiliario en Colombia. Mediante la articulación armónica entre modelos canónicos estructurados, orquestación transaccional con PostgreSQL, extracción híbrida con salvaguardas heurísticas y consolidación transversal con triple firma, el sistema garantiza que cada dato consignado en una minuta final provenga de una fuente auténtica, verificable e inmutable.